Clustering et Classification de Styles de Combattants UFC

Aymane Aarab

Machine Learning Non Supervisé / Supervisé • Python / Google Colab • scikit-learn • MLflow

Combats	Combattants	Pool clustering	Features	Clusters	DT acc.	RF acc.
8 482	4 448	835	17	5	76.0%	88.6%

Table des matières

1 Contexte et Objectifs **2**

2 Données et Exploration (NB1 — EDA) **2**

2.1 Jeux de données 2

2.2 Valeurs manquantes notables 2

2.3 Observations clés 3

3 Ingénierie des Features (NB2) **3**

3.1 Transformation structurelle 3

3.2 Les 17 features de style 3

4 Prétraitement et Mise à l'Échelle (NB3) **3**

4.1 Choix du scaler : RobustScaler 4

4.2 Analyse en Composantes Principales (ACP) 4

5 Clustering (NB4) **4**

5.1 Algorithmes évalués 4

5.2 Métriques d'évaluation 4

5.3 Résultats K-Means 5

5.4 Modèle retenu : K-Means, K=5 5

5.5 Profils des 5 clusters 5

6 Classification et Arbre de Décision (NB5) **5**

6.1 Du clustering à la classification 6

6.2 Arbre de Décision — résultats 6

6.3 Forêt Aléatoire — résultats 6

6.4 Importance des features (RF) 7

6.5 Comparaison des deux modèles 7

7 Suivi MLflow **7**
7.1 Illustrations des runs MLflow 7

8 Résultats, Limites et Perspectives **8**
8.1 Récapitulatif des résultats 8
8.2 Limites 8

Conclusion **8**

1 Contexte et Objectifs

L'UFC regroupe les meilleurs combattants de MMA (*Mixed Martial Arts*) au monde. Chaque athlète développe un style propre combinant boxe, kickboxing, lutte et jiu-jitsu. Ce projet répond à la question suivante :

« Peut-on identifier automatiquement des archétypes de styles de combat à partir des seules statistiques de combats ? »

Il s'agit d'un problème d'**apprentissage non supervisé** : aucune étiquette de style n'existe a priori. L'approche combine clustering puis classification supervisée.

Pipeline en 5 notebooks Google Colab :

NB1 EDA → **NB2** Features → **NB3** Scaling → **NB4** Clustering → **NB5** Classification

2 Données et Exploration (NB1 — EDA)

2.1 Jeux de données

Table 1 – Description des fichiers sources

Fichier	Contenu	Lignes	Colonnes
`raw_fighters.csv`	Profils combattants (taille, poids, palmarès)	4 448	12
`raw_fights_detailed.csv`	Stats détaillées par combat (frappes, TD, sub.)	8 482	55

Les deux fichiers sont reliés par `Fighter_Id`. 2 637 combattants apparaissent dans les deux sources.

2.2 Valeurs manquantes notables

Table 2 – Valeurs manquantes dans `raw_fighters.csv`

Colonne	Manquantes	%
Reach (allonge)	1 946	43.8% → *supprimée*
Stance	850	19.1% → *encodée si disponible*
Taille	324	7.3% → *supprimée*

2.3 Observations clés

— Les colonnes statistiques sont au format `"X of Y"` → parsing requis.
— Le temps de contrôle est au format `MM:SS` → conversion en secondes.
— 62% des combats se terminent aux points, 33% par KO/TKO, 20% par soumission.
— `sig_str_pm` et `td_per_fight` ont une faible corrélation → deux axes de style indépendants, idéaux pour le clustering.

Seuil de filtrage

395 combattants n'ont qu'un seul combat dans le dataset. Leurs moyennes sont trop bruitées. Le seuil **minimum 5 combats** est retenu, donnant **835 combattants** exploitables.

3 Ingénierie des Features (NB2)

3.1 Transformation structurelle

Le fichier brut est combat-centré (1 ligne = 1 combat, 2 combattants côte à côte). Il est transformé en vue **combattant-centré** par empilement des deux perspectives : $8\,482 \times 2 = 16\,964$ lignes, puis agrégation par combattant.

3.2 Les 17 features de style

Table 3 – Features construites par groupe

Groupe	Feature	Définition
Volume	`sig_str_pm`	Frappes significatives par minute
	`td_per_fight`	Takedowns réussis par combat
	`sub_per_fight`	Tentatives de soumission par combat
	`kd_per_fight`	Knockdowns par combat
	`ctrl_sec_per_fight`	Secondes de contrôle au sol par combat
Précision	`sig_str_accuracy`	Frappes atterries / tentées
	`td_accuracy`	Takedowns réussis / tentés (0 si jamais tenté)
Zone cible	`head_ratio`	% frappes à la tête
	`body_ratio`	% frappes au corps
	`leg_ratio`	% frappes aux jambes
Position	`dist_ratio`	% frappes à distance
	`clinch_ratio`	% frappes en clinch
	`ground_ratio`	% frappes au sol
Finish	`ko_rate`	Taux de combats finis par KO/TKO
	`sub_rate`	Taux de combats finis par soumission
	`dec_rate`	Taux de combats allant aux points
	`win_rate`	Taux de victoires global

Sortie : `fighter_features.csv` — 835 combattants × 17 features, zéro valeur manquante, journalisé dans MLflow.

4 Prétraitement et Mise à l'Échelle (NB3)

4.1 Choix du scaler : RobustScaler

Plusieurs features présentent une forte asymétrie (*skewness*) :

Table 4 – Asymétrie des features les plus déséquilibrées

Feature	Skewness	Impact
`sig_str_pm`	4.80	Valeur max = 51 frappes/min
`sub_per_fight`	3.22	Rare mais extrême
`kd_per_fight`	2.61	Distribution très asymétrique

Le **StandardScaler** serait biaisé par ces outliers (il utilise moyenne et écart-type). Le **RobustScaler** utilise médiane et IQR :

$$x_{\text{scaled}} = \frac{x - \text{médiane}}{\text{IQR}} = \frac{x - Q_2}{Q_3 - Q_1}$$

Il est quasi-insensible aux valeurs extrêmes.

4.2 Analyse en Composantes Principales (ACP)

Table 5 – Variance cumulée expliquée par l'ACP

PC	PC1	PC2	PC3	PC4	PC5	PC6	PC7
Cumulé	19.9%	33.8%	44.5%	53.2%	61.1%	68.4%	74.3%

7 composantes capturent 74.3% de la variance. Deux versions sont produites pour le clustering : features complètes (17 dims) et ACP (7 dims).

5 Clustering (NB4)

5.1 Algorithmes évalués

Trois algorithmes ont été testés : **K-Means** (features complètes + ACP), **Clustering Hiérarchique** (liaison Ward) et **DBSCAN**.

5.2 Métriques d'évaluation

Le **score de silhouette** mesure la cohésion intra-cluster et la séparation inter-clusters :

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, +1]$$

Le **score de Davies-Bouldin** (plus bas = meilleur) mesure le ratio dispersion interne / distance entre centres.

5.3 Résultats K-Means

Table 6 – Métriques K-Means — features complètes

K	Inertie	Silhouette	Davies-Bouldin
2	7 034	0.156	2.21
3	6 526	0.134	2.15
4	6 112	0.099	2.39
5	**5 798**	**0.091**	**2.22**
6	5 553	0.093	2.12
7	5 319	0.096	2.03
8	5 140	0.091	1.97

Pourquoi des scores bas sont normaux ici

Les scores de silhouette (0.09–0.16) reflètent la nature même du MMA : les combattants modernes sont polyvalents et leurs styles se chevauchent. Le critère décisif est l'**interprétabilité humaine** des clusters obtenus.

DBSCAN s'est révélé inadapté : la distribution uniforme des combattants dans l'espace des features empêche la formation de régions denses exploitables.

5.4 Modèle retenu : K-Means, K=5

Clustering final

K-Means, K=5, features complètes, RobustScaler Silhouette = 0.091 DB = 2.22

5.5 Profils des 5 clusters

Table 7 – Profils moyens des clusters (valeurs originales non scalées)

Style	N	str/min	td/fight	ctrl(s)	ko_rate	dec_rate
Aggressive Strikers	190	4.41	0.50	68.8	0.507	0.367
Balanced Decision Fighters	180	3.87	0.77	112.4	0.237	0.590
Submission Hunters	126	2.76	0.87	118.8	0.449	0.254
Volume Strikers	209	3.09	1.20	142.7	0.217	0.538
Wrestlers / Grapplers	130	2.84	2.80	306.6	0.239	0.529

Combattants représentatifs :

- **Aggressive Strikers :** Donald Cerrone, Dustin Poirier, Andrei Arlovski
- **Balanced Decision Fighters :** Jon Jones, Jeremy Stephens, Alex Caceres
- **Submission Hunters :** Charles Oliveira, Jim Miller, Nate Diaz
- **Volume Strikers :** Neil Magny, Francisco Trinaldo, Angela Hill
- **Wrestlers / Grapplers :** Tito Ortiz, Randy Couture, Demian Maia

6 Classification et Arbre de Décision (NB5)

6.1 Du clustering à la classification

Les labels de cluster deviennent des cibles supervisées. Le problème devient une **classification multiclasse à 5 classes**. Division stratifiée : 80% entraînement (668) / 20% test (167).

6.2 Arbre de Décision — résultats

12 expériences ont été journalisées dans MLflow en faisant varier `max_depth` (2–None), `criterion` (gini/entropy), `min_samples_split` et `min_samples_leaf`.

Table 8 – Résultats Arbre de Décision (sélection)

depth	criterion	Train	Test	CV-5
3	gini	0.757	0.713	0.690
4	gini	0.811	0.754	0.747
5	**gini**	**0.849**	**0.760**	**0.753**
6	gini	0.898	0.731	0.758
None	gini	1.000	0.677	0.746

Règles produites par l'arbre (depth=4, interprétables) :

```
|--- dist_ratio <= 0.58
|   |--- ctrl_sec_per_fight <= 231.45
|   |   |--- dec_rate <= 0.48
|   |   |   |--- clinch_ratio <= 0.05  ->  Wrestlers / Grapplers
|   |   |   |--- clinch_ratio >  0.05  ->  Submission Hunters
|   |--- ctrl_sec_per_fight >  231.45
|   |   |--- td_per_fight   >  1.45   ->  Wrestlers / Grapplers
|--- dist_ratio > 0.58
|   |--- ko_rate > 0.29
|   |   |--- head_ratio > 0.40        ->  Aggressive Strikers
|   |--- ko_rate <= 0.29              ->  Volume / Balanced Strikers
```

6.3 Forêt Aléatoire — résultats

11 expériences MLflow testant `n_estimators` (50–200), `max_depth` (5, 8, None) et `max_features` (sqrt, log2).

Meilleure Forêt Aléatoire

`n_estimators=200`, `max_depth=8`, `max_features='sqrt'` **Test : 88.6%** CV-5 : 87.5%

Table 9 – Rapport de classification — Random Forest (200 arbres)

Style	Précision	Rappel	F1	Support
Aggressive Strikers	0.95	0.95	0.95	38
Balanced Decision Fighters	0.90	0.97	0.93	36
Submission Hunters	0.81	0.88	0.85	25
Volume Strikers	0.86	0.86	0.86	42
Wrestlers / Grapplers	0.90	0.73	0.81	26
Accuracy			**0.89**	**167**

6.4 Importance des features (RF)

Table 10 – Top 6 features les plus discriminantes

Feature	Question posée	Importance
`dist_ratio`	Frappe-t-il à distance ?	12.4%
`head_ratio`	Vise-t-il la tête ?	11.9%
`ko_rate`	Est-il un finisseur ?	11.0%
`ctrl_sec_per_fight`	Contrôle-t-il au sol ?	10.5%
`td_per_fight`	Plaque-t-il son adversaire ?	9.3%
`ground_ratio`	Frappe-t-il au sol ?	8.5%

6.5 Comparaison des deux modèles

Table 11 – DT vs RF — bilan

Modèle	Test	CV-5	Overfit	Atout
Arbre de Décision (d=5)	0.760	0.753	0.089	Règles lisibles, interprétable
Forêt Aléatoire (n=200)	0.886	0.875	0.019	Précision maximale

7 Suivi MLflow

MLflow est intégré dès le notebook 2. Les données sont stockées dans Google Drive (`mlruns/`) et consultables localement via `mlflow ui`.

7.1 Illustrations des runs MLflow

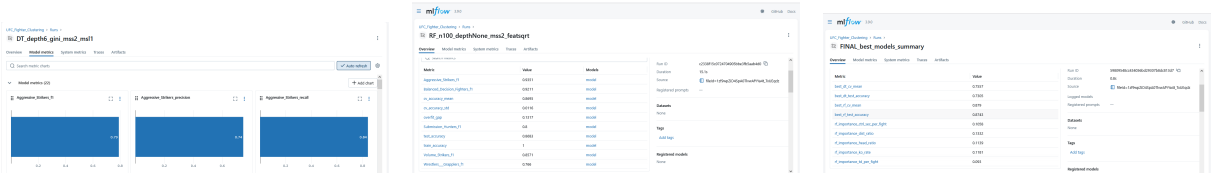

Figure 1 – Exemples de visualisations MLflow : Paramètres, métriques et F1-score par classe.

Table 12 – Expériences et runs journalisés

Expérience	Notebook	Runs	Contenu
`fighter_style_clustering`	NB2 – NB4	3+	Params, métriques, CSV
`fighter_style_classification`	NB5 (DT)	12	Hyperparamètres, F1 par classe
`fighter_style_classification`	NB5 (RF)	11	Hyperparamètres, F1 par classe
`fighter_style_classification`	NB5 final	1	Modèles .pkl sauvés
Total		**27+**	

Chaque run enregistre : paramètres du modèle, accuracy train/test/CV, overfit gap, F1-score par classe et modèle sérialisé.

8 Résultats, Limites et Perspectives

8.1 Récapitulatif des résultats

Table 13 – Résultats clés par étape

Étape	Résultat
EDA	8 482 combats analysés, 835 combattants retenus (seuil min. 5 combats)
Features	17 features de style, zéro valeur manquante, matrice 835 × 17
Scaling	RobustScaler — résistance aux outliers (skewness max = 4.80)
Clustering	5 styles K-Means, silhouette = 0.091, interprétables et validés
Classif.	RF 88.6% test / 87.5% CV — DT 76.0% test avec règles lisibles
MLflow	27+ runs, traçabilité complète, modèles versionnnés et reproductibles

8.2 Limites

1. **Labels issus du clustering :** leur qualité dépend de K-Means, limité par le chevauchement naturel des styles MMA.
2. **Pas de dimension temporelle :** les stats sont agrégées sur toute la carrière, ignorant l'évolution du combattant.
3. **Adversaires non pris en compte :** les stats varient selon le niveau et le style des opposants.
4. **Dataset UFC uniquement :** ne couvre pas Bellator ou ONE FC.

Conclusion

Ce projet démontre qu'il est possible d'identifier automatiquement des archétypes de styles de combat dans le MMA à partir de statistiques brutes.

Les **5 styles identifiés** correspondent à des catégories reconnues par les experts MMA, validant la pertinence de l'approche non supervisée. La **Forêt Aléatoire** (88.6%) confirme que ces styles sont statistiquement cohérents. L'**Arbre de Décision** (76%) offre une transparence totale avec des règles directement interprétables par un analyste sportif.